

Previsione del Valore di Mercato dei Calciatori

Gruppo 43: Giuseppe Scordo

9 settembre 2026

Sommario

Nel calcio moderno, la stima del valore di mercato di un giocatore rappresenta una sfida analitica complessa, influenzata da una moltitudine di variabili che spesso trascendono dalle prestazioni sul campo. Quantificare il potenziale di un giovane attaccante o la solidità di un portiere di esperienza è un'esigenza quotidiana nel calciomercato, cruciale per la sostenibilità finanziaria di ogni club. Questo progetto esplora l'applicazione di algoritmi di Machine Learning per prevedere le valutazioni economiche dei calciatori basandosi su statistiche prestazionali, dati anagrafici e contesti di lega. Nello specifico, sono stati addestrati e messi a confronto un modello di Ridge Regression, implementato in PyTorch, e un algoritmo Random Forest Regressor. L'elaborato non si limita al calcolo delle metriche di errore globali, ma indaga a fondo i bias dei modelli, analizzando le discrepanze di valutazione tra i diversi ruoli tattici e le anomalie economiche dei campionati europei, come il sovrapprezzo sistematico della Premier League.

Indice

1	Dataset e Preprocessing	3
2	Metodologia e Modelli	4
2.1	Ridge Regression	4
2.2	Random Forest Regressor	5
3	Risultati e Metriche Globali	5
4	Analisi degli Errori per Categoria	5
4.1	Discrepanze per Ruolo Tattico	6
4.2	Anomalie Geografiche e la "Premier League Tax"	6
5	Feature Importance e Interpretabilità dei Modelli	6
5.1	Random Forest	7
5.2	Modello Lineare	7

6	Conclusioni e Sviluppi Futuri	7
6.1	Conclusioni	7
6.2	Sviluppi Futuri	8

1 Dataset e Preprocessing

Il dataset su cui si basa il progetto è Football Data From Transfer Market, reperibile su Kaggle. Il dataset originale è strutturato come un database relazionale contenente lo storico delle valutazioni, le anagrafiche dei giocatori e i referti delle singole partite.

I dati grezzi sono stati aggregati e fusi al fine di ottenere un singolo record per ogni calciatore. Il campione è stato inoltre filtrato per includere i giocatori militanti nei primi cinque campionati europei.

Il dataset finale utilizzato per l'addestramento è composto dalla variabile target e da un set di feature predittive, suddivisibili nelle seguenti categorie:

- **Variabile Target:** `market_value_in_eur`, che rappresenta l'attuale stima economica del cartellino del giocatore espressa in Euro. Nei passaggi successivi, per stabilizzare la varianza, questa variabile è stata trasformata logaritmicamente.
- **Feature Numeriche (Anagrafiche e Prestazionali):**
 - **Age:** Età del calciatore, fattore cruciale per stimare la rivendibilità e le prospettive.
 - **appearances_count** e **minutes_played:** Indicano rispettivamente il numero di presenze stagionali e il minutaggio complessivo, definendo il livello di impiego del giocatore.
 - **goals** e **assists:** Contributi offensivi assoluti.
 - **goals_per_90** e **assists_per_90:** Metriche avanzate che normalizzano il rendimento offensivo per 90 minuti giocati.
- **Feature Categoriche (Tattiche e Geografiche):**
 - **Ruolo:** Variabili per distinguere portieri, difensori, centrocampisti e attaccanti.
 - **Campionato di Appartenenza:** Variabili delle leghe, tra cui Premier League, Serie A, Bundesliga, Ligue 1 e La Liga.
 - **Metadati:** Un flag binario (`has_appearance_data`) che indica la presenza o meno di statistiche dettagliate sul campo per il giocatore in questione.

Alla fine della selezione delle feature dalle tabelle del dataset ho ottenuto 10694 esempi con 17 features ciascuno.

La fase di preparazione dei dati è stata fondamentale per garantire la corretta convergenza dei modelli, in particolar modo per la regressione lineare, e per arricchire lo spazio delle feature, permettendo agli algoritmi di cogliere dinamiche di mercato più complesse. Il processo si è articolato in tre fasi principali:

1. **Espansione Polinomiale:** Nel contesto del calciomercato, molte relazioni non sono strettamente lineari. Ad esempio, il valore di un giocatore tende a crescere con l'età fino a raggiungere un apice, per poi decrescere rapidamente (la cosiddetta *curva di invecchiamento*). Per modellare matematicamente questi comportamenti e le sinergie tra le variabili, le 7 feature numeriche originali sono state trasformate

utilizzando `PolynomialFeatures` (con grado $d = 2$). Questa operazione ha generato i termini quadratici (es. Age^2) e tutte le interazioni binarie (es. $\text{Age} \times \text{goals}$), espandendo il sottoinsieme numerico da 7 a 35 feature.

2. **Standardizzazione (`StandardScaler`):** Le 35 feature numeriche sono state normalizzate trasformando i valori originali in z -score, applicando la formula:

$$z = \frac{x - \mu}{\sigma}$$

3. **Integrazione delle Variabili Categoricalhe:** Le variabili relative al ruolo e al campionato di appartenenza sono state trasformate in variabili dummy. Queste ultime, composte unicamente da valori binari (0 o 1), sono state concatenate alle feature numeriche standardizzate, portando la dimensionalità complessiva del tensore di input a 44 feature predittive totali.

2 Metodologia e Modelli

Al fine di valutare approcci predittivi di diversa natura, il progetto mette a confronto un modello parametrico lineare, addestrato tramite discesa del gradiente, e un modello non parametrico basato su Random Forest. Entrambi i modelli sono stati addestrati per minimizzare l'errore di previsione sul logaritmo del valore di mercato, per poi riconvertire le stime nella scala monetaria originale in fase di valutazione.

2.1 Ridge Regression

Il primo modello implementato è una Regressione Lineare Multipla costruita utilizzando l'ecosistema PyTorch. Il modello è stato addestrato iterativamente minimizzando la funzione di costo tramite l'algoritmo di ottimizzazione.

Per ridurre l'overfitting penalizziamo pesi grandi. In **Ridge** (L_2) la loss è definita come:

$$J_{\lambda}(\vartheta) = \frac{1}{2m} \|X\vartheta - y\|_2^2 + \frac{\lambda}{2m} \sum_{j=1}^n \vartheta_j^2$$

Durante la fase di addestramento, questo termine di regolarizzazione è stato implementato impostando il parametro `weight_decay` all'interno dell'ottimizzatore.

Il processo di training ha previsto i seguenti iperparametri:

- **Epoche:** 4000
- **Learning Rate (lr):** 0.0001
- **Momentum:** 0.9
- **Weight Decay (λ):** 0.01

2.2 Random Forest Regressor

Come termine di paragone è stato impiegato un *Random Forest Regressor*. L'algoritmo combina le previsioni di molteplici alberi decisionali addestrati su sottoinsiemi casuali dei dati e delle feature.

A differenza del modello lineare, la Random Forest non calcola coefficienti o pesi globali, ma stima il valore target suddividendo iterativamente lo spazio delle feature per minimizzare la varianza interna di ciascun nodo foglia. Il modello è stato istanziato componendo una foresta di 200 alberi decisionali, permettendo di ottenere stime estremamente stabili e di mitigare il rischio di overfitting sui dati di training.

3 Risultati e Metriche Globali

Le prestazioni dei modelli sono state valutate confrontando le previsioni con i valori reali di mercato sul set di validazione/test. Poiché in fase di addestramento il target è stato trasformato logaritmicamente, le stime sono state riconvertite nella scala originale (in milioni di Euro) prima di calcolare gli errori assoluti e quadratici.

Le metriche di riferimento utilizzate per la valutazione sono:

- **MSE e RMSE:** Per penalizzare maggiormente gli errori di grande entità.
- **MAE:** L'errore medio assoluto in milioni di Euro, che offre l'interpretazione di business più diretta.
- **R^2 :** Per misurare la porzione di varianza del valore di mercato spiegata dalle feature.

Modello	MSE	RMSE	MAE	R^2
Ridge Regression	50.9057	7.1348	2.1026	0.5169
Random Forest Regressor	35.9284	5.9940	1.9931	0.6545

Come si evince dai risultati, il modello Random Forest dimostra una maggiore capacità di cogliere le non-linearità del mercato calcistico, ottenendo un R^2 superiore e un errore medio più contenuto rispetto alla controparte lineare, la quale risulta maggiormente rigida nonostante l'espansione polinomiale delle feature.

4 Analisi degli Errori per Categoria

Una delle fasi più critiche di questo progetto consiste nell'analisi granulare degli errori. Valutare esclusivamente le metriche globali rischia di nascondere i bias intrinseci del mercato calcistico. Segmentando le previsioni del modello attraverso le categorie, sono emerse dinamiche economiche altamente polarizzate, sia a livello tattico che geografico.

4.1 Discrepanze per Ruolo Tattico

L'algoritmo ha mostrato gradi di confidenza nettamente diversi a seconda della posizione occupata dal giocatore sul terreno di gioco:

- **Portieri:** Rappresentano la categoria più prevedibile in assoluto. Il modello ha registrato un MAE minimo (circa 0.61 milioni di Euro) e un coefficiente R^2 molto elevato (0.76). Questo dimostra che il mercato dei portieri segue logiche di prezzo estremamente stabili e contenute, strettamente ancorate ai dati anagrafici e di impiego. Da notare che questo risultato è stato raggiunto anche senza dati puramente difensivi.
- **Attaccanti:** Al contrario, i giocatori con spiccate attitudini offensive presentano il MAE più alto tra i ruoli di movimento (circa 2.04 milioni di Euro). Ciononostante, il loro R^2 ha raggiunto il picco di 0.77. Ciò indica che il modello comprende perfettamente le metriche che alzano il prezzo degli attaccanti (es. gol e assist), ma fatica a calibrare le cifre assolute, spesso astronomiche, pagate per i top player di questo reparto.
- **Difensori e Centrocampisti:** Si attestano su valori intermedi (con un R^2 rispettivamente di 0.60 e 0.62). La maggiore difficoltà del modello nel prevedere con esattezza queste categorie deriva probabilmente dalla natura delle statistiche a disposizione: il contributo di un mediano di rottura o di un difensore centrale è molto più difficile da quantificare tramite semplici gol o assist rispetto a quello di un attaccante.

4.2 Anomalie Geografiche e la "Premier League Tax"

La scomposizione degli errori per campionato di appartenenza (Top 5 Leagues) ha permesso di quantificare alcune delle dinamiche più discusse del calciomercato europeo:

- **La Premier League Tax:** I giocatori militanti nel campionato inglese presentano l'errore medio più alto (MAE di 3.25 milioni di Euro) nonostante una varianza spiegata comunque alta (R^2 di 0.71). Questo certifica matematicamente l'esistenza di un sovrapprezzo sistematico: il modello gerarchizza correttamente i giocatori in base alle prestazioni, ma non riesce a replicare l'irrazionalità dovuta alle disponibilità economiche dei club inglesi.
- **Razionalità e Anomalie:** La Bundesliga tedesca si attesta come il mercato più strutturato e prevedibile (R^2 di 0.77), indicando valutazioni economiche fortemente proporzionali alle reali statistiche. All'estremo opposto, la Ligue 1 francese crolla a un R^2 di 0.49, evidenziando un mercato fortemente sbilanciato, con un'alta varianza probabilmente introdotta dalle valutazioni anomale e fuori scala di una singola super-potenza economica del campionato (Il PSG).

5 Feature Importance e Interpretabilità dei Modelli

Oltre alla minimizzazione dell'errore predittivo, un obiettivo centrale di questa analisi è l'interpretabilità, ovvero la comprensione di quali variabili guidino effettivamente le

valutazioni economiche nel calciomercato. A tal fine, sono stati estratti e messi a confronto i "pesi" e le "regole" apprese dai due modelli.

5.1 Random Forest

Per migliorare l'interpretabilità è stata calcolata l'importanza relativa delle feature. Questa operazione ha rivelato le priorità assolute del mercato:

- **Età e Impiego:** Le statistiche mostrano che `Age` e `appearances_count` dominano incontrastate la classifica dell'importanza. Questo conferma che, prima ancora dei gol segnati, il mercato paga le prospettive future dell'investimento (l'età) e la certezza del suo utilizzo costante (le presenze e i minuti giocati).
- **Impatto Offensivo:** Feature come `goals` e `assists` seguono dopo, in combinazione con le features più impattanti. Risulta interessante notare come l'algoritmo dia priorità a queste metriche rispetto all'appartenenza a specifici campionati (con la sola eccezione della Premier per i motivi elencati precedentemente), indicando che il talento offensivo mantiene un valore trasversale e universale.

5.2 Modello Lineare

Il modello lineare offre una prospettiva complementare, con alcune piccole differenze:

- **Età e Impiego:** Anche in questo caso `Age` e `appearances_count` dominano la classifica dell'importanza delle feature, ma con un distacco percentuale minore rispetto a quanto avveniva nella Random Forest. Questo indica che il modello lineare distribuisce i pesi predittivi in modo leggermente più omogeneo.
- **Impatto Offensivo:** Un risultato di particolare rilevanza è il peso assegnato alle metriche normalizzate. Le feature `goals_per_90` e `assists_per_90` risultano nettamente più impattanti rispetto alle loro versioni assolute, arrivando a superare persino l'impatto generato dall'appartenenza alla Premier League. Ciò dimostra che il modello lineare è in grado di isolare e premiare l'efficienza reale del calciatore, valutando il rendimento effettivo in relazione ai minuti giocati.

6 Conclusioni e Sviluppi Futuri

6.1 Conclusioni

Il progetto ha dimostrato l'efficacia degli algoritmi di Machine Learning nel decodificare le complesse dinamiche del calciomercato europeo. Il confronto tra la Ridge Regression e il Random Forest Regressor ha evidenziato due approcci complementari alla previsione del valore di mercato:

- Il **Random Forest** si è rivelato lo strumento più accurato in termini di metriche globali, dimostrando una superiore capacità di mappare le non-linearità del mercato.

- Il **Modello Lineare**, d'altro canto, ha offerto una straordinaria interpretabilità, dando più importanza all'efficienza reale di un giocatore (tramite le metriche `per_90`) rispetto al puro volume di gioco o del campionato di appartenenza, come ipotizzato in principio.

L'analisi degli errori ha inoltre quantificato dinamiche di settore precedentemente considerate solo su base empirica, come l'estrema razionalità nelle valutazioni dei portieri e l'esistenza matematica di una "Premier League Tax" che distorce i valori dei giocatori militanti nel campionato inglese.

6.2 Sviluppi Futuri

Sebbene i modelli abbiano raggiunto risultati eccellenti, il progetto apre la strada a diverse implementazioni future per incrementare ulteriormente la precisione e l'affidabilità delle stime:

- **Dati difensivi e di costruzione del gioco:** Integrare metriche specifiche come i *tackle* vinti, le intercettazioni o la *media_passaggi* riusciti potrebbe colmare il gap di prevedibilità (R^2 inferiore) riscontrato attualmente nelle posizioni di gioco arretrate e nel centrocampo di interdizione.
- **Impatto delle competizioni europee:** Includere feature relative alle presenze e alle prestazioni nelle competizioni UEFA creerebbe una migliore segmentazione dei giocatori di vertice all'interno di uno stesso campionato. Questo aiuterebbe a stabilizzare la varianza in leghe molto polarizzate, come il campionato francese, dove vi è un divario economico e tecnico enorme tra le squadre che partecipano alla Champions League e il resto della classifica.