

Previsione del Valore di Mercato dei Calciatori

Gruppo 43: Giuseppe Scordo

30 settembre 2026

Sommario

Nel calcio moderno, la stima del valore di mercato di un giocatore rappresenta una sfida analitica complessa, influenzata da una moltitudine di variabili che spesso trascendono dalle prestazioni sul campo. Quantificare il potenziale di un giovane attaccante o la solidità di un portiere di esperienza è un'esigenza quotidiana nel calciomercato, cruciale per la sostenibilità finanziaria di ogni club. Questo progetto esplora l'applicazione di algoritmi di Machine Learning per prevedere le valutazioni economiche dei calciatori basandosi su statistiche prestazionali, dati anagrafici e contesti di lega. Nello specifico, sono stati addestrati e messi a confronto un modello di Ridge Regression, implementato in PyTorch, e un algoritmo Random Forest Regressor. L'elaborato non si limita al calcolo delle metriche di errore globali, ma indaga a fondo i bias dei modelli, analizzando le discrepanze di valutazione tra i diversi ruoli tattici e le anomalie economiche dei campionati europei, come il sovrapprezzo sistematico della Premier League.

Indice

1	Dataset e Preprocessing	3
2	Metodologia e Modelli	6
2.1	Ridge Regression	6
2.2	Random Forest Regressor	7
3	Risultati e Metriche Globali	7
4	Analisi degli Errori per Categoria	8
4.1	Discrepanze per Ruolo Tattico	8
4.2	Anomalie Geografiche e la "Premier League Tax"	9
4.3	Analisi degli Outlier e dei Casi Estremi	9
5	Feature Importance e Interpretabilità dei Modelli	11
5.1	Random Forest	11
5.2	Modello Lineare	12

6	Demo e Casi Studio	13
6.1	Allineamento della Pipeline di Preprocessing	13
6.2	Analisi Comparativa e Casi Studio	13
6.2.1	Caso Studio 1: Il Difensore Titolare (Dodô)	14
6.2.2	Caso Studio 2: L'Attaccante Standard (Riccardo Orsolini)	15
6.2.3	Caso Studio 3: L'Outlier Estremo (Kylian Mbappé)	16
7	Conclusioni e Sviluppi Futuri	17
7.1	Conclusioni	17
7.2	Sviluppi Futuri	17

1 Dataset e Preprocessing

Inizialmente, lo studio si basava su *Football Players 1992-2025 Top 5 Leagues*, una raccolta di statistiche e valori di mercato relativi ai cinque principali campionati europei. Tuttavia, fin dalle prime fasi esplorative sono emerse criticità legate all'elevata dispersione temporale e alla disomogeneità dei dati storici; il dataset inoltre non risulta più reperibile sulla piattaforma Kaggle.

Per queste ragioni, il progetto è stato riorientato sul dataset *Football Data from Transfermarkt*, anch'esso reperibile su Kaggle. La sorgente originale è strutturata come un database relazionale che raccoglie lo storico delle valutazioni economiche, i dati anagrafici dei calciatori e i referti delle singole partite. Questa seconda opzione si è rivelata nettamente più solida e gestibile, sia per la chiarezza della documentazione allegata, sia per la possibilità di garantire una maggiore compattezza temporale isolando esclusivamente la valutazione più recente di ciascun atleta associandola alle statistiche globali.

In fase di preprocessing, le diverse tabelle di dati grezzi sono state aggregate e unite al fine di consolidare un singolo record per ogni calciatore. Il campione risultante è stato infine filtrato per includere unicamente i giocatori militanti nei primi cinque campionati europei.

Nella prima fase di selezione erano incluse esclusivamente le seguenti variabili:

- **Variabile Target:**

- `market_value_in_eur`: rappresenta la stima economica attuale del cartellino del giocatore, espressa in Euro. Nelle fasi successive di preprocessing, questa variabile è stata sottoposta a trasformazione logaritmica per stabilizzarne la varianza e gestire l'asimmetria della distribuzione.

- **Feature Numeriche (Anagrafiche e Prestazionali):**

- `Age` e `Age_sq`: l'età anagrafica e il suo termine quadratico rivestono un ruolo cruciale. Sebbene i giocatori più giovani tendano ad avere valutazioni elevate per via della loro futuribilità, la ridotta esperienza iniziale comporta spesso un valore inferiore rispetto agli atleti nel pieno della maturità calcistica (a metà carriera), per poi calare nuovamente a fine carriera. L'introduzione immediata della feature quadratica permette di catturare questa relazione non lineare.
- `appearances_count` e `minutes_played`: quantificano il volume di impiego e l'esperienza accumulata sul campo da ciascun calciatore.
- `goals` e `assists`: misurano il contributo offensivo in termini assoluti.




Figura 1: Distribuzione e andamento del valore di mercato in funzione dell'età anagrafica dei calciatori.

- **Feature Categorie (Tattiche e Geografiche):**

- **Ruolo Tattico:** variabili per distinguere portieri, difensori, centrocampisti e attaccanti.
- **Campionato di Appartenenza:** variabili identificative delle leghe, tra cui Premier League, Serie A, Bundesliga, Ligue 1 e La Liga.

Tuttavia, questa configurazione preliminare ha prodotto risultati insoddisfacenti, registrando un RMSE pari a circa 8 milioni di Euro e un coefficiente di determinazione $R^2 = 0.198$. Poiché tali metriche sono state riscontrate sia in fase di training sia in fase di testing, è emerso chiaramente un problema di *underfitting* (elevato bias). Per superare questo limite, si è proceduto a una fase di rielaborazione delle feature, costruendo un nuovo dataframe con un set ampliato di variabili.

Il dataset definitivo utilizzato per l'addestramento dei modelli è costituito dalla variabile target e da un set arricchito di feature predittive, suddivisibili nelle seguenti categorie:

- **Variabile Target:** `market_value_in_eur`, che rappresenta l'attuale stima economica del cartellino del giocatore espressa in Euro. Nei passaggi successivi, per stabilizzarne la varianza, questa variabile è stata trasformata su scala logaritmica.
- **Feature Numeriche (Anagrafiche e Prestazionali):**
 - **Age:** età del calciatore, fattore cruciale per stimare le prospettive di crescita e la futura rivendibilità.

- `appearances_count` e `minutes_played`: indicano rispettivamente il numero di presenze stagionali e il minutaggio complessivo, definendo il livello di impiego del giocatore.
- `goals` e `assists`: contributi offensivi assoluti.
- `goals_per_90` e `assists_per_90`: metriche avanzate di efficienza che normalizzano il rendimento offensivo rapportandolo a 90 minuti effettivi di gioco.

- **Feature Categorie e Metadati (Tattiche e Geografiche):**

- **Ruolo Tattico:** variabili per distinguere portieri, difensori, centrocampisti e attaccanti.
- **Campionato di Appartenenza:** variabili identificative delle leghe, tra cui Premier League, Serie A, Bundesliga, Ligue 1 e La Liga.
- **Metadati:** un flag binario (`has_appearance_data`) che indica la disponibilità o meno di statistiche dettagliate sul campo per il giocatore in esame.

Al termine del processo di estrazione e selezione delle variabili, il dataset consolidato conta 10.694 esempi (giocatori), descritti complessivamente da 17 colonne (16 feature predittive e 1 variabile target).

La fase di preprocessing si è rivelata fondamentale per garantire la corretta convergenza degli algoritmi, in particolar modo per il modello lineare, e per arricchire lo spazio delle feature, permettendo di cogliere dinamiche di mercato non lineari. Il processo si è articolato in tre passaggi principali:

1. **Espansione Polinomiale:** Nel contesto del calciomercato, molte relazioni non seguono un andamento strettamente lineare. Ad esempio, il valore di un atleta tende a crescere con l'età fino a raggiungere un apice nel pieno della maturità agonistica, per poi decrescere rapidamente (la cosiddetta *curva di invecchiamento*). Per modellare matematicamente questi comportamenti e le sinergie tra le variabili nel modello lineare, le 7 feature numeriche continue sono state espanse tramite `PolynomialFeatures` (con grado $d = 2$, escludendo il termine di bias). Questa operazione ha generato i termini quadratici (es. Age^2 che avevamo incluso precedentemente) e tutte le interazioni binarie (es. $\text{Age} \times \text{goals}$), ampliando il sottoinsieme numerico da 7 a 35 feature (7 lineari, 7 quadratiche e 21 interazioni).
2. **Standardizzazione (`StandardScaler`):** Poiché l'elevazione a potenza genera scale numeriche molto distanti tra loro, le 35 feature numeriche sono state standardizzate trasformando i valori originali in z -score secondo la relazione:

$$z = \frac{x - \mu}{\sigma}$$

dove μ rappresenta la media campionaria e σ la deviazione standard, calcolate esclusivamente sul *Training Set* per prevenire fenomeni di *data leakage* verso i set di validazione e di test.

3. **Integrazione delle Variabili Categoriche:** Le variabili qualitative relative al ruolo tattico e al campionato di appartenenza sono state codificate in variabili *dummy* (binarie), affiancate al flag `has_appearance_data`. Queste 9 feature composte unicamente da valori binari (0 o 1) sono state concatenate alle 35 feature numeriche standardizzate senza subire ulteriori riscalature, portando la dimensionalità complessiva del tensore di input per il modello lineare a 44 feature predittive totali.

2 Metodologia e Modelli

Al fine di valutare approcci predittivi di diversa natura, il progetto mette a confronto un modello parametrico lineare, addestrato tramite discesa del gradiente, e un modello non parametrico basato su Random Forest. Entrambi i modelli sono stati addestrati per minimizzare l'errore di previsione sul logaritmo del valore di mercato, per poi riconvertire le stime nella scala monetaria originale in fase di valutazione.

2.1 Ridge Regression

Il primo modello implementato consiste in una Regressione Lineare Multipla sviluppata attraverso il framework PyTorch. L'addestramento è avvenuto in modo iterativo, minimizzando la funzione di costo tramite l'algoritmo di discesa del gradiente stocastico (SGD).

Per contrastare il fenomeno dell'*overfitting* indotto dall'espansione polinomiale delle feature, è stata introdotta una penalizzazione sui pesi di magnitudine elevata. Adottando la regolarizzazione **Ridge** (L_2), la funzione obiettivo (*loss function*) assume la seguente forma:

$$J_\lambda(\vartheta) = \frac{1}{2m} \|X\vartheta - y\|_2^2 + \frac{\lambda}{2m} \sum_{j=1}^n \vartheta_j^2$$

dove m indica il numero di esempi di addestramento, n il numero di feature predittive, ϑ il vettore dei pesi del modello e λ il coefficiente di regolarizzazione. In fase di validazione, l'approccio Ridge si è dimostrato più efficace sia rispetto alla regressione priva di regolarizzazione, sia rispetto alla penalizzazione Lasso (L_1), garantendo un coefficiente di determinazione R^2 leggermente superiore.

Dal punto di vista implementativo, la penalizzazione L_2 è stata integrata direttamente nell'ottimizzatore di PyTorch valorizzando il parametro `weight_decay`. La configurazione finale degli iperparametri, calibrata empiricamente sul Validation Set, prevede:

- **Epoche (epochs):** 4.000, numero di iterazioni necessario per garantire la piena stabilizzazione della curva di apprendimento.
- **Tasso di apprendimento (learning_rate):** 0.0001, valore ottimale per evitare oscillazioni o divergenze del gradiente nello spazio polinomiale.
- **Momento (momentum):** 0.9, parametro rivelatosi determinante per accelerare la discesa del gradiente; in sua assenza, l'addestramento richiedeva un numero proibitivo di epoche senza riuscire a raggiungere il minimo globale.

- **Regolarizzazione (`weight_decay`, λ):** 0.01, individuato come compromesso ideale tra il controllo della varianza dei pesi e la capacità predittiva del modello.

2.2 Random Forest Regressor

Come modello di riferimento non lineare, vista la natura parametrica e la semplicità strutturale della regressione lineare, è stato implementato un *Random Forest Regressor* tramite la libreria Scikit-Learn; Algoritmo di ensemble learning che combina le previsioni di molteplici alberi decisionali, ciascuno addestrato su campioni estratti tramite *bootstrap* e su sottoinsiemi casuali di feature.

A differenza dell'approccio lineare, la Random Forest non stima coefficienti o pesi globali, bensì predice il valore target partizionando ricorsivamente lo spazio delle variabili in modo da minimizzare la varianza residua (impurezza) all'interno di ciascun nodo foglia. Il modello è stato istanziato configurando una foresta di 200 stimatori (`n_estimators=200`), una dimensione che ha permesso di stabilizzare la varianza delle predizioni e di mitigare efficacemente il rischio di *overfitting* sul *Training Set*.

Un'evidenza sperimentale particolarmente interessante riguarda l'impatto dell'espansione polinomiale: contrariamente alle attese teoriche, secondo cui i modelli ad albero non necessitano di trasformazioni non lineari, la Random Forest ha registrato prestazioni superiori quando addestrata sull'intero set di 44 feature polinomiali rispetto alle sole 16 feature di base. Dal punto di vista geometrico, questo comportamento si spiega con il fatto che gli alberi decisionali eseguono tagli ortogonali agli assi, ossia valutano una variabile alla volta ad ogni nodo; fornire esplicitamente i termini di interazione (es. $\text{Age} \times \text{goals}$) offre all'algoritmo delle "scorciatoie" informative, permettendogli di isolare sinergie complesse con un singolo taglio anziché doverle approssimare tramite una lunga sequenza di ramificazioni.

3 Risultati e Metriche Globali

Le prestazioni dei modelli sono state valutate confrontando le predizioni con i reali valori di mercato sul Test Set. Poiché in fase di addestramento la variabile target è stata trasformata su scala logaritmica, le stime prodotte dagli algoritmi sono state preventivamente riconvertite nella scala monetaria originale (espressa in milioni di Euro) tramite trasformazione inversa esponenziale, procedendo poi al calcolo dei residui.

Le metriche di riferimento adottate per la valutazione quantitativa sono:

- **MSE e RMSE:** impiegati per misurare la dispersione quadratica degli errori, penalizzando in modo più severo gli scostamenti di grande entità (tipici dei giocatori *top player*).
- **MAE:** rappresenta l'errore medio assoluto espresso in milioni di Euro e offre l'interpretazione di dominio più immediata.
- **Coefficiente di determinazione (R^2):** utilizzato per quantificare la proporzione di varianza del valore di mercato spiegata complessivamente dalle feature del modello.

Il modello lineare ha registrato un netto miglioramento evolutivo: si è passati dalle prestazioni fortemente limitate della versione preliminare di Regressione Lineare (addestrata sul set ridotto di feature):

$$\text{MSE} = 65.2062 \quad | \quad \text{RMSE} = 8.0750 \quad | \quad \text{MAE} = 2.7473 \quad | \quad R^2 = 0.1978$$

a risultati decisamente più solidi in seguito al processo di selezione delle feature e all'espansione polinomiale dello spazio delle variabili, come riportato nella Tabella 1:

Tabella 1: Confronto delle prestazioni globali dei modelli sul Test Set (errori espressi in milioni di Euro).

Modello	MSE	RMSE	MAE	R^2
Ridge Regression (Polinomiale)	50.9057	7.1348	2.1026	0.5169
Random Forest Regressor	35.9284	5.9940	1.9931	0.6545

Come si evince dal confronto sperimentale, il modello Random Forest dimostra una superiore capacità di catturare le non-linearità intrinseche del mercato calcistico, raggiungendo un coefficiente R^2 sensibilmente più elevato (0.6545) e un errore medio più contenuto rispetto alla controparte lineare; quest'ultima mantiene una maggiore rigidità strutturale nonostante l'introduzione delle feature polinomiali.

4 Analisi degli Errori per Categoria

Una delle fasi più critiche di questo progetto consiste nell'analisi granulare degli errori. Valutare esclusivamente le metriche globali rischia di nascondere i bias intrinseci del mercato calcistico. Segmentando le previsioni del modello attraverso le categorie, sono emerse dinamiche economiche altamente polarizzate, sia a livello tattico che geografico.

4.1 Discrepanze per Ruolo Tattico

L'algoritmo ha mostrato gradi di confidenza nettamente diversi a seconda della posizione occupata dal giocatore sul terreno di gioco:

- **Portieri:** Rappresentano la categoria più prevedibile in assoluto. Il modello ha registrato un MAE minimo (circa 0.61 milioni di Euro) e un coefficiente R^2 molto elevato (0.76). Questo dimostra che il mercato dei portieri segue logiche di prezzo estremamente stabili e contenute, strettamente ancorate ai dati anagrafici e di impiego. Da notare che questo risultato è stato raggiunto anche senza dati puramente difensivi.
- **Attaccanti:** Al contrario, i giocatori con spiccate attitudini offensive presentano il MAE più alto tra i ruoli di movimento (circa 2.04 milioni di Euro). Ciononostante, il loro R^2 ha raggiunto il picco di 0.77. Ciò indica che il modello comprende perfettamente le metriche che alzano il prezzo degli attaccanti (es. gol e assist), ma fatica a calibrare le cifre assolute, spesso astronomiche, pagate per i top player di questo reparto.

- **Difensori e Centrocampisti:** Si attestano su valori intermedi (con un R^2 rispettivamente di 0.60 e 0.62). La maggiore difficoltà del modello nel prevedere con esattezza queste categorie deriva probabilmente dalla natura delle statistiche a disposizione: il contributo di un mediano di rottura o di un difensore centrale è molto più difficile da quantificare tramite semplici gol o assist rispetto a quello di un attaccante.

4.2 Anomalie Geografiche e la "Premier League Tax"

La scomposizione degli errori per campionato di appartenenza (Top 5 Leagues) ha permesso di quantificare alcune delle dinamiche più discusse del calciomercato europeo:

- **La Premier League Tax:** I giocatori militanti nel campionato inglese presentano l'errore medio più alto (MAE di 3.25 milioni di Euro) nonostante una varianza spiegata comunque alta (R^2 di 0.71). Questo certifica matematicamente l'esistenza di un sovrapprezzo sistematico: il modello gerarchizza correttamente i giocatori in base alle prestazioni, ma non riesce a replicare l'irrazionalità dovuta alle disponibilità economiche dei club inglesi.
- **Razionalità e Anomalie:** La Bundesliga tedesca si attesta come il mercato più strutturato e prevedibile (R^2 di 0.77), indicando valutazioni economiche fortemente proporzionali alle reali statistiche. All'estremo opposto, la Ligue 1 francese crolla a un R^2 di 0.49, evidenziando un mercato fortemente sbilanciato, con un'alta varianza probabilmente introdotta dalle valutazioni anomale e fuori scala di una singola super-potenza economica del campionato (Il PSG).

4.3 Analisi degli Outlier e dei Casi Estremi

Per comprendere più a fondo la distribuzione dei residui e l'origine dei valori di RMSE osservati, è stata condotta un'ispezione puntuale sui 10 casi del *Test Set* caratterizzati dal maggiore errore assoluto per ciascun algoritmo. I risultati di tale analisi, messi a confronto con la mediana dell'intero campione di test, sono riportati nella Tabella 2.

Tabella 2: Confronto sui 10 maggiori errori assoluti (in milioni di Euro) e metriche di sintesi sul Test Set.

Rank	Ridge Regression			Random Forest		
	Reale	Predetto	Errore	Reale	Predetto	Errore
1	45.0	191.0	146.0	120.0	42.7	77.3
2	100.0	201.4	101.4	100.0	26.5	73.5
3	80.0	9.9	70.1	80.0	17.8	62.2
4	90.0	21.8	68.2	150.0	94.6	55.4
5	100.0	34.6	65.4	75.0	20.1	54.9
6	75.0	12.3	62.7	60.0	7.3	52.7
7	120.0	65.2	54.8	70.0	18.9	51.1
8	70.0	17.0	53.0	90.0	39.4	50.6
9	60.0	11.6	48.4	80.0	30.4	49.6
10	75.0	30.2	44.8	70.0	25.5	44.5
Media Top 10	71.48 M€			57.19 M€		
MAE Globale	2.1026 M€			1.8818 M€		
Mediana Globale	0.3851 M€			0.2598 M€		

Dall’analisi comparativa dei dati emergono tre evidenze di rilievo metodologico e applicativo:

1. **Divario tra Media e Mediana (Asimmetria degli errori):** Confrontando l’errore medio assoluto (MAE) con l’errore mediano sull’intero *Test Set*, si osserva una differenza marcata. Mentre il MAE si attesta intorno a 2.10 M€ per la regressione Ridge e a 1.88 M€ per la Random Forest, la mediana scende rispettivamente a 0.3851 M€ (385 mila Euro) e a un eccellente 0.2598 M€ (circa 260 mila Euro). Ciò dimostra che per il 50% dei calciatori nel campione il modello commette uno scarto inferiore a un terzo di milione di Euro; le metriche globali (in particolare l’RMSE) risultano quindi fortemente inflazionate da una ristretta coda di *outlier* costituita dai cosiddetti *top player* (valutazioni reali comprese tra 60 e 150 M€).
2. **Esplosione esponenziale nel modello polinomiale (Sovrastima):** Analizzando le prime due posizioni della Ridge Regression, si notano due gravi episodi di sovrastima (un giocatore da 45.0 M€ valutato 191.0 M€, con un errore di 146.0 M€, e uno da 100.0 M€ predetto a 201.4 M€). Questo comportamento è una conseguenza diretta della combinazione tra l’espansione polinomiale ($d = 2$) e la trasformazione inversa esponenziale ($\exp(\hat{y}) - 1$). In presenza di calciatori con statistiche stagionali fuori dal comune (es. elevatissimo minutaggio o picchi di `goals_per_90`), i termini quadratici assumono valori molto grandi nel dominio logaritmico che, una volta riconvertiti tramite esponenziale nella scala in Euro, generano stime fuori scala.
3. **Robustezza strutturale della Random Forest e il limite dei “fuoriclasse”:** A differenza del modello lineare, la Random Forest dimezza quasi l’errore massimo (77.3 M€ contro 146.0 M€) e riduce l’errore medio sui primi 10 casi critici da 71.48 M€ a 57.19 M€. Poiché gli alberi decisionali calcolano le predizioni come media dei

valori presenti nelle foglie di addestramento, l'algoritmo è strutturalmente vincolato all'interno del *range* storico osservato e risulta immune da esplosioni esponenziali. Al contempo, si nota come tutti i 10 peggiori errori della Random Forest siano *sottostime* di campioni affermati (valori reali tra 60 e 150 M€). Tali discrepanze non dipendono da limiti dell'algoritmo, bensì da fattori esogeni non presenti nel dataset: le valutazioni oltre la soglia dei 70–80 M€ sono infatti determinate da dinamiche contrattuali, clausole rescissorie, impatto mediatico o prestazioni nelle coppe internazionali, variabili che le sole statistiche di campionato non possono catturare.

5 Feature Importance e Interpretabilità dei Modelli

Oltre alla minimizzazione dell'errore predittivo, un obiettivo centrale di questa analisi è l'interpretabilità, ovvero la comprensione di quali variabili guidino effettivamente le valutazioni economiche nel calciomercato. A tal fine, sono stati estratti e messi a confronto i pesi e le regole apprese dai due modelli.

5.1 Random Forest




Figura 2: Importanza relativa delle variabili predittive (*Feature Importance*) nel modello Random Forest.

Per migliorare l'interpretabilità è stata calcolata l'importanza relativa delle feature. Questa operazione ha rivelato le priorità assolute del mercato:

- **Età e Impiego:** Le statistiche mostrano che **Age** e **appearances_count** dominano incontrastate la classifica dell'importanza. Questo conferma che, prima ancora

dei gol segnati, il mercato paga le prospettive future dell'investimento (l'età) e la certezza del suo utilizzo costante (le presenze e i minuti giocati).

- **Impatto Offensivo:** Feature come `goals` e `assists` seguono dopo, in combinazione con le features più impattanti. Risulta interessante notare come l'algoritmo dia priorità a queste metriche rispetto all'appartenenza a specifici campionati (con la sola eccezione della Premier per i motivi elencati precedentemente), indicando che il talento offensivo mantiene un valore trasversale e universale.

5.2 Modello Lineare




Figura 3: Importanza relativa delle variabili predittive (*Feature Importance*) nel modello di regressione Lineare.

Il modello lineare offre una prospettiva complementare, con alcune piccole differenze:

- **Età e Impiego:** Anche in questo caso `Age` e `appearances_count` dominano la classifica dell'importanza delle feature, ma con un distacco percentuale minore rispetto a quanto avveniva nella Random Forest. Questo indica che il modello lineare distribuisce i pesi predittivi in modo leggermente più omogeneo.
- **Impatto Offensivo:** Un risultato di particolare rilevanza è il peso assegnato alle metriche normalizzate. Le feature `goals_per_90` e `assists_per_90` risultano nettamente più impattanti rispetto alle loro versioni assolute, arrivando a superare persino l'impatto generato dall'appartenenza alla `Premier League`. Ciò dimostra che il modello lineare è in grado di isolare e premiare l'efficienza reale del calciatore, valutando il rendimento effettivo in relazione ai minuti giocati.

6 Demo e Casi Studio

The screenshot shows a web application titled "Stima del Valore di Mercato" (Market Value Estimation). On the left, there is a sidebar with "Impostazioni Predizione" (Prediction Settings) where "Random Forest" is selected. The main area contains a form with two columns: "Anagrafica e Impiego" (Personal and Employment) and "Metriche Offensive e Lega" (Offensive Metrics and League). The form fields are: Età (27), Gol (5), Presenze (180), Assist (18), Minuti Giocati (14500), Campionato (Serie A), and Ruolo (Defender). A red button at the bottom says "Calcola con Random Forest".

Figura 4: Interfaccia grafica della demo

Per validare empiricamente le performance dei modelli addestrati e per fornire un'interfaccia fruibile per la stima in tempo reale, ho sviluppato un'applicazione web interattiva utilizzando il framework *Streamlit*. L'applicativo permette di inserire le statistiche assolute di carriera di un calciatore (età, presenze, minuti giocati, ruolo, gol, assist e campionato di appartenenza) e di ottenere una stima istantanea del valore di mercato elaborata dai due modelli finali: la Random Forest e la Ridge Regression.


6.1 Allineamento della Pipeline di Preprocessing

Un aspetto critico nello sviluppo della demo è stato il perfetto allineamento tra i dati di input inseriti dall'utente e i tensori attesi dai modelli. L'architettura neurale e l'albero decisionale richiedono un vettore di input di 44 feature. Per replicare l'esatta logica della fase di training, il sistema acquisisce i dati dall'interfaccia e costruisce un vettore base di 16 feature (7 numeriche e 9 categoriche tramite One-Hot Encoding). Successivamente, l'intero vettore viene standardizzato utilizzando le metriche μ e σ salvate durante l'addestramento. Solo a questo punto le 7 feature numeriche normalizzate vengono isolate e passate all'algoritmo di espansione polinomiale, generando 35 feature derivate (incluso interazioni e quadrati, come i parametri *per_90*). Infine, queste vengono concatenate alle variabili categoriche, restituendo l'input finale di 44 dimensioni, che viene poi valutato e ritrasformato esponenzialmente per ottenere il valore in milioni di Euro.

6.2 Analisi Comparativa e Casi Studio

Per testare la robustezza dei modelli e la loro reazione a input differenti, sono stati analizzati tre profili di giocatori con caratteristiche statistiche profondamente diverse.

6.2.1 Caso Studio 1: Il Difensore Titolare (Dodô)



The image shows the Transfermarkt profile of Dodô, a defender for Fiorentina. The profile includes a player photo, a list of trophies (3), and a blue box indicating a market value of 16.00 million euros, updated on 29/05/2026. The player's details are as follows:

Info	Value
Nato il:	17/11/1998 (27)
Luogo di nascita:	Taubaté
Nazionalità:	Brasile
Altezza:	1,66 m
Posizione:	Terzino destro
Procuratore:	Bertolucci Sports
Era nazionale:	Brasile
Gare/gol:	0 / 0

Club: Fiorentina, Serie A. Livello: Primo livello. In rosa da: 22/07/2022. Contratto fino: 30/06/2027.

Figura 5: Profilo di Dodô su Transfermarkt

Come primo profilo profilo ho analizzato un giocatore di rottura, con alti volumi di gioco ma scarso apporto offensivo (27 anni, 180 presenze, 14.500 minuti, 5 gol e 8 assist in Serie A), il cui valore di mercato reale si attesta intorno ai 16 milioni di euro.

- **Random Forest:** Ha stimato **14.1 Milioni di Euro**. Il modello ha compreso le logiche non lineari legate al ruolo (*Defender*), intuendo che per un difensore l'alto minutaggio compensa i pochi gol.



The image shows a web interface titled "Stima del Valore di Mercato" (Market Value Estimation). It prompts the user to enter player statistics and select an algorithm. The input fields are as follows:

Anagrafica e Impiego	Metrische Offensive e Lega
Età: 27	Gol: 5
Presenze: 180	Assist: 18
Minuti Giocati: 14500	Campionato: Serie A
Ruolo: Defender	

A red button labeled "Calcola con Random Forest" is present. Below it, a green box displays the result: "Valore Stimato (Random Forest): 14.1 Milioni di Euro".

Figura 6: Risultati di random forest sul profilo di dodô

- **Ridge Regression:** Ha sottostimato il giocatore a **6.2 Milioni di Euro**. La regressione ha penalizzato fortemente l'assenza di reti, non riuscendo a bilanciare linearmente il peso del ruolo con la carenza di feature offensive.

Stima del Valore di Mercato

Inserisci le statistiche del giocatore e scegli l'algoritmo per ottenere una stima.

Anagrafica e Impiego	Metriche Offensive e Lega
Età: 27	Gol: 5
Presenze: 180	Assist: 18
Minuti Giocati: 14500	Campionato: Serie A
Ruolo: Defender	

Calcola con Ridge Regression (PyTorch)

Valore Stimato (Ridge Regression (PyTorch)): 6.4 Milioni di Euro

Figura 7: Risultati della regressione sul profilo di dodô

6.2.2 Caso Studio 2: L'Attaccante Standard (Riccardo Orsolini)

#7 Riccardo Orsolini

Bologna
Serie A

Livello: **Primo livello**
In rosa da: **01/07/2019**
Contratto fino: **30/06/2031**

Nato il: **24/01/1997 (29)**
Luogo di nascita: **Ascoli Piceno**
Nazionalità: **Italia**

Altezza: **1,86 m**
Posizione: **Ala destra**

Nazionale: **Italia**
Gare/gol: **13 / 2**

15,00 mln €
Aggiornato al: 29/05/2026

Figura 8: Profilo di Orsolini su Transfermarkt

Il secondo test ha riguardato un profilo perfettamente distribuito all'interno della media del dataset (29 anni, 290 presenze, 18.000 minuti, 75 gol, 50 assist in Serie A), con un valore reale tra i 15 e i 20 milioni di euro.

- **Convergenza dei Modelli:** La Random Forest ha predetto **19.3 Milioni di Euro**, mentre la Ridge Regression ha restituito **14.5 Milioni di Euro**.

In assenza di valori estremi e con un apporto offensivo coerente, entrambi i modelli hanno dimostrato un'eccellente capacità di generalizzazione, convergendo verso valutazioni estremamente precise e confermando la solidità dei modelli, inoltre possiamo osservare un'estrema precisione nel caso di Ridge Regression nella predizione di dati tipici.

Stima del Valore di Mercato

Inserisci le statistiche del giocatore e scegli l'algoritmo per ottenere una stima.

Anagrafica e Impiego

Età: 29

Presenze: 290

Minuti Giocati: 18000

Ruolo: Attack

Metriche Offensive e Lega

Gol: 75

Assist: 50

Campionato: Serie A

Calcola con Random Forest

Valore Stimato (Random Forest): 19.3 Milioni di Euro

(a) Stima Random Forest

Stima del Valore di Mercato

Inserisci le statistiche del giocatore e scegli l'algoritmo per ottenere una stima.

Anagrafica e Impiego

Età: 29

Presenze: 290

Minuti Giocati: 18000

Ruolo: Attack

Metriche Offensive e Lega

Gol: 75

Assist: 50

Campionato: Serie A

Calcola con Ridge Regression (PyTorch)

Valore Stimato (Ridge Regression (PyTorch)): 14.5 Milioni di Euro

(b) Stima Ridge Regression

Figura 9: Confronto delle stime su Orsolini.

6.2.3 Caso Studio 3: L'Outlier Estremo (Kylian Mbappé)

#10 Kylian Mbappé

Nato il: 20/12/1998 (27) | Altezza: 1,80 m | Attuale Nazionale: Francia

Luogo di nascita: Paris | Posizione: Punta centrale | Gare/gol: 107 / 67

Nazionalità: Francia

Real Madrid LaLiga

Livello: Primo livello | In rosa da: 01/07/2024 | Contratto fino: 30/06/2029

200,00 mln € | Aggiornato al: 22/07/2026

Figura 10: Profilo di Mbappé su Transfermarkt

L'ultimo test è stato condotto inserendo i dati storici di un fuoriclasse assoluto (27 anni, 470 presenze, 37.500 minuti giocati, 340 gol e 155 assist). Questo caso ha evidenziato la principale divergenza matematica tra i due approcci:

- **Random Forest:** Ha stimato un valore di **92.3 Milioni di Euro**. L'algoritmo ha gestito l'outlier sottostimandolo, in quanto gli alberi decisionali non estrapolano oltre il valore massimo appreso nel *training set*, fornendo un "tetto" realistico.
- **Ridge Regression:** Ha generato una stima del tutto fuori scala pari a **492.2 Milioni di Euro**. La natura lineare-esponenziale del modello ha causato un'esplosione numerica: non avendo un limite superiore, l'espansione polinomiale di valori così estremi ha portato la stima a quasi mezzo miliardo, dimostrando i limiti dei modelli lineari sui valori anomali.

Stima del Valore di Mercato

Inserisci le statistiche del giocatore e scegli l'algoritmo per ottenere una stima.

Anagrafica e Impiego		Metriche Offensive e Lega	
Et�	27	Gol	340
Presenze	460	Assist	155
Minuti Giocati	37500	Campionato	La Liga
Ruolo	Attack		

Calcola con Random Forest

Valore Stimato (Random Forest): 92.3 Milioni di Euro

(a) Stima Random Forest

Stima del Valore di Mercato

Inserisci le statistiche del giocatore e scegli l'algoritmo per ottenere una stima.

Anagrafica e Impiego		Metriche Offensive e Lega	
Et�	27	Gol	340
Presenze	460	Assist	155
Minuti Giocati	37500	Campionato	La Liga
Ruolo	Attack		

Calcola con Ridge Regression (PyTorch)

Valore Stimato (Ridge Regression (PyTorch)): 492.2 Milioni di Euro

(b) Stima Ridge Regression

Figura 11: Confronto delle stime su Mbapp .

7 Conclusioni e Sviluppi Futuri

7.1 Conclusioni

Il progetto ha dimostrato l'efficacia degli algoritmi di Machine Learning nel decodificare le complesse dinamiche del calciomercato europeo. Il confronto tra la Ridge Regression e il Random Forest Regressor ha evidenziato due approcci complementari alla previsione del valore di mercato:

- Il **Random Forest** si   rivelato lo strumento pi  accurato in termini di metriche globali, dimostrando una superiore capacit  di mappare le non-linearit  del mercato.
- Il **Modello Lineare**, d'altro canto, ha offerto una straordinaria interpretabilit , dando pi  importanza all'efficienza reale di un giocatore (tramite le metriche `per_90`) rispetto al puro volume di gioco o del campionato di appartenenza, come ipotizzato in principio.

L'analisi degli errori ha inoltre quantificato dinamiche di settore precedentemente considerate solo su base empirica, come l'estrema razionalit  nelle valutazioni dei portieri e l'esistenza matematica di una "Premier League Tax" che distorce i valori dei giocatori militanti nel campionato inglese.

7.2 Sviluppi Futuri

Sebbene i modelli abbiano raggiunto risultati eccellenti, il progetto apre la strada a diverse implementazioni future per incrementare ulteriormente la precisione e l'affidabilit  delle stime:

- **Dati difensivi e di costruzione del gioco:** Integrare metriche specifiche come i *tackle* vinti, le intercettazioni o la *media_passaggi* riusciti potrebbe colmare il gap di

prevedibilità (R^2 inferiore) riscontrato attualmente nelle posizioni di gioco arretrate e nel centrocampo di interdizione.

- **Impatto delle competizioni europee:** Includere feature relative alle presenze e alle prestazioni nelle competizioni UEFA creerebbe una migliore segmentazione dei giocatori di vertice all'interno di uno stesso campionato. Questo aiuterebbe a stabilizzare la varianza in leghe molto polarizzate, come il campionato francese, dove vi è un divario economico e tecnico enorme tra le squadre che partecipano alla Champions League e il resto della classifica.